




Наборы данных


CRISP-DM

- CRISP-DM (Cross-Industry Standard Process for Data Mining - межотраслевой стандартный процесс для исследования данных) - методология исследования данных.
- Методологически он включает в себя описание типичных фаз проекта, задач в составе каждой из этих фаз и объяснение взаимосвязей между существующими задачами.
- Как модель процесса CRISP-DM предоставляет обзор жизненного цикла исследования данных.



CRISP-DM

- 1. Понимание бизнес-целей (Business Understanding) - Как правило, на этапе решения задачи машинного обучения цель уже задана.
- 2. Начальное изучение данных (Data Understanding) – + Первичное изучение набора данных, первичная визуализация данных.
- **3. Подготовка данных (Data Preparation) – +. Очистка данных, удаление аномалий. Выделение из исходных данных признаков (features) для решения задачи.**
- 4. Моделирование (Modeling) – +. Разработка модели в терминах алгоритмов машинного обучения.
- 5. Оценка (Evaluation) – +. Оценка качества разработанной модели с помощью методов оценки качества, используемых в машинном обучении.
- 6. Внедрение (Deployment) – -. Не является этапом исследовательской задачи.



Подготовка данных

- Сбор данных. Разные форматы и типы в зависимости от источника. Например, видеоданные и табличные данные нелегко использовать вместе.
- Очистка данных. Удаление выбросов, исправление некорректных значений.
- Разметка данных. Разметка в обработке изображений.
- Проверка
- Визуализация

Преобразование данных и признаков

- Табличные данные
- Текстовые данные
- Изображения, наборы изображений и видео



- Матрицы признакового описания объектов(X)


Iris

- Iris — небольшой набор данных для задачи классификации, опубликованный еще в 1936 году Робертом Фишером, используя данные биолога Эдгара Андерсона. В этом наборе данных представлены по 50 описаний цветков одного из трех типов — Ирис щетинистый (*Iris setosa*), Ирис виргинский (*Iris virginica*) и Ирис разноцветный (*Iris versicolor*).
- Для каждого цветка измерены четыре величины — длина чашелистника (англ. sepal length), ширина чашелистника (sepal width), длина лепестка (англ. petal length), ширина лепестка (англ. petal width). Все цветки промаркированы одним из трех типов, что позволяет тестировать на нем алгоритмы классификации. Интересное наблюдение — один из классов цветков линейно отделим от двух других.

Длина чашелистника	Ширина чашелистника	Длина лепестка	Ширина лепестка	Класс
5.1	3.5	1.4	0.2	setosa
7.0	3.2	4.7	1.4	versicolor
6.3	3.3	6.0	2.5	virginica

CIFAR-10

- CIFAR-10 (Canadian Institute For Advanced Research) — еще один большой набор изображений, который обычно используется для тестирования алгоритмов машинного обучения. Он содержит 60 000 цветных картинок размером 32x32 пикселя, размеченных в один из десяти классов: самолеты, автомобили, коты, олени, собаки, лягушки, лошади, корабли и грузовики. В наборе данных по 6000 картинок каждого класса



Emotions

- Emotions is a dataset of English Twitter messages with six basic emotions: anger, fear, joy, love, sadness, and surprise. For more detailed information please refer to the paper. Note that the paper does contain a larger data set with eight emotions being considered.
- [jeffnyman/emotions](https://jeffnyman.com/emotions) · Datasets at Hugging Face

name	train	validation	test
split	16000	2000	2000
unsplit	416809	n/a	n/a

An example bit of data looks like this:

```
{
  "text": "im feeling quite sad and sorry for myself but ill snap out of it soon",
  "label": 0
}
```

Data Fields

The data fields are:

- `text`: a string feature.
- `label`: a classification label, with possible values including sadness (0), joy (1), love (2), anger (3), fear (4), surprise (5).

Примеры ресурсов с размещенными данными

- <https://huggingface.co/>
- [Kaggle: Your Machine Learning and Data Science Community](#)

Теория измерений

- Теория измерений – это теория о классификации переменных величин по природе информации, которая содержится в числах – значениях этих переменных величин. Происхождение переменной величины накладывает ограничения на множество действий, которые можно производить с этой величиной. Иными словами, для каждой переменной величины существует класс допустимых преобразований (КДП), которые корректно применимы ко всем значениям этой величины.
- Классификация величин по измеримости была предложена С.С.Стивенсом в 1946 году. Каждая группа величин, имеющих общие допустимые преобразования, называется шкалой измерений.

Шкалы

- Принято считать, что любая шкала может обладать следующими характеристиками:
- описание,
- порядок,
- расстояние,
- естественная точка отсчёта,
- естественная единица измерения.

Номинальная шкала

- Шкала, в которой есть только характеристика «описание»
 - Возможные операции: определение равенства
 - Пример: нумерация игроков футбольной команды
-
- В шкале наименований допустимыми являются все взаимно-однозначные преобразования. В этой шкале числа используются как метки, только для различения объектов. В шкале наименований измерены, например, номера телефонов, автомашин, паспортов, студенческих билетов. Пол людей тоже измерен в шкале наименований, результат измерения принимает два значения - мужской, женский. Очевидно, что не имеет смысла складывать номера телефонов или умножать серии паспортов.
-
- КДП: биективные преобразования.

Порядковая (ранговая) шкала

- + вторая характеристика: ПОРЯДОК
- Операции: установление отношений «больше-меньше»
- Пример: ранжирование по признаку
- В порядковой шкале числа используются не только для различения объектов, но и для установления порядка между объектами. Простейшим примером являются оценки знаний учащихся. Заметим, что в средней школе применяются оценки 2, 3, 4, 5, а в высшей школе ровно тот же смысл выражается словесно - неудовлетворительно, удовлетворительно, хорошо, отлично. Этим подчеркивается "нечисловой" характер оценок знаний учащихся. В порядковой шкале допустимыми являются все строго монотонные преобразования.
- КДП: все строго монотонные преобразования.

Интервальная шкала

- + характеристика: РАССТОЯНИЕ
- Операция: равенство интервалов
- Пример: температура, календарные даты, баллы при тестировании
- По шкале интервалов измеряют величину потенциальной энергии или координату точки на прямой. В этих случаях на шкале нельзя отметить ни естественное начало отсчета, ни естественную единицу измерения. Исследователь должен сам задать точку отсчета и сам выбрать единицу измерения. Допустимыми преобразованиями в шкале интервалов являются линейные возрастающие преобразования, т.е. линейные функции. Температурные шкалы Цельсия и Фаренгейта связаны именно такой зависимостью: $^{\circ}\text{C} = 5/9 (^{\circ}\text{F} - 32)$, где $^{\circ}\text{C}$ - температура (в градусах) по шкале Цельсия, а $^{\circ}\text{F}$ - температура по шкале Фаренгейта.
- КДП: все преобразования вида $x' = kx + b$

Шкала отношений

- В шкалах отношений есть естественное начало отсчета - нуль, но нет естественной единицы измерения. По шкале отношений измерены большинство физических единиц: масса тела, длина, заряд, а также цены в экономике. Допустимыми преобразованиями шкале отношений являются подобные (изменяющие только масштаб). Другими словами, линейные возрастающие преобразования без свободного члена. Примеры использования таких преобразований: пересчет цен из одной валюты в другую по фиксированному курсу, перевод массы из килограмм в фунты.
- КДП: все преобразования вида $x' = kx$

Шкала разностей

- В шкале разностей есть естественная единица измерения, но нет естественного начала отсчета. Время измеряется по шкале разностей, если год (или сутки - от полудня до полудня) принимаем естественной единицей измерения, и по шкале интервалов в общем случае. На современном уровне знаний естественного начала отсчета времени указать нельзя. Допустимыми преобразованиями шкале разностей являются сдвиги.
- КДП: все преобразования вида $x' = x + b$

Абсолютная шкала

- + характеристика: ЕСТЕСТВЕННАЯ ТОЧКА ОТСЧЕТА
- Операции: равенство отношений
- Пример: длина, вес, высота
- Только для абсолютной шкалы результаты измерений - числа в обычном смысле слова. Примером является число людей в комнате. Для абсолютной шкалы допустимым является только тождественное преобразование. $x' = x$

Иерархия шкал

Качественные шкалы



Количественные шкалы



Иерархия шкал

- Все шкалы делят также на 2 большие группы: качественные и количественные. К качественным шкалам относят номинальную и порядковую, к количественным - все остальные. Это разделение показывает разницу в природе шкал: например, невозможно утверждать, что школьная оценка 2 настолько же хуже оценки 4, насколько 3 хуже оценки 5, поэтому порядковые шкалы относят к качественным. В то же время, для тел разной массы аналогичное утверждение корректно: тело массой 5 кг настолько же тяжелее тела массой 3 кг, насколько тело массой 4 кг тяжелей тела массой 2 кг. Таким образом, шкалы отношений - это количественные шкалы.
- Очевидно, что КДП одной шкалы может полностью включать в себя КДП другой. Тогда говорят, что вторая шкала сильнее первой. На иллюстрации изображена иерархия шкал.

Шкалы в анализе данных

- При анализе данных следует помнить о том, к какой шкале измерений относятся исследуемые величины:
- Алгоритм анализа данных должен быть инвариантен относительно КДП исследуемой величины
- Алгоритм, применимый к более слабой шкале, применим и к более сильной.

Примеры аномалий данных

- Пропущенные значения
- Выбросы, аномалии в существующей шкале – значение сильно отличается от среднего значения в остальных строках таблицы
- Контекстные аномалии – недопустимые значения в столбце
- Групповые аномалии – недопустимые значения группы на определенном этапе, некорректный замер характеристики для группы