



Метрики качества в задачах анализа данных

Задача классификации

- Имеется множество объектов (ситуаций), разделённых некоторым образом на классы. Задано конечное множество объектов, для которых известно, к каким классам они относятся. Это множество называется обучающей выборкой. Классовая принадлежность остальных объектов не известна. Требуется построить алгоритм, способный классифицировать произвольный объект из исходного множества.
- Классифицировать объект — значит, указать номер (или наименование класса), к которому относится данный объект.
- Классификация объекта — номер или наименование класса, выдаваемый алгоритмом классификации в результате его применения к данному конкретному объекту.

Задача классификации

- X – множество описаний объекта
- Y – конечное множество номеров (меток) классов
- Существует неизвестная зависимость (отображение):

$$y^*: X \rightarrow Y$$

- Результат известен на конечном множестве объектов

$$X^{\bar{m}} = \{(x_1, y_1), \dots, (x_m, y_m)\}$$

- Задача: построить алгоритм для отображения

$$a: X \rightarrow Y$$



МЕТОД К БЛИЖАЙШИХ СОСЕДЕЙ (МЕТРИЧЕСКИЙ МЕТОД)

Гипотеза компактности

*Гипотеза компактности (для классификаций):
Близкие объекты, как правило, лежат в одном классе.*

- Неформальная интерпретация:
- скажи мне, кто твой друг, и я скажу, кто ты.

Метод k ближайших соседей (kNN — k nearest neighbours) метрический алгоритм для классификации объектов, основанный на оценивании сходства объектов.

Классифицируемый объект относится к тому классу, которому принадлежат ближайшие к нему объекты обучающей выборки.

Алгоритм:

- 1 Вычислить расстояние до каждого из объектов обучающей выборки
- 2 Отобрать k объектов обучающей выборки, расстояние до которых минимально
- 3 Класс классифицируемого объекта — это класс, наиболее часто встречающийся среди k ближайших соседей

Мера близости

Что такое близкие объекты? Задана функция расстояния $\rho : X \times X \rightarrow [0, \infty)$.

Виды функций расстояния:

- Евклидово: $\rho(x_i, x_j) = \sqrt{\sum_{k=1}^m w_k (x_i^{(k)} - x_j^{(k)})^2}$
- L_p -метрика: $\rho(x_i, x_j) = \left(\sum_{k=1}^m w_k |x_i^{(k)} - x_j^{(k)}|^p \right)^{1/p}$
- L_∞ -метрика: $\rho(x_i, x_j) = \max_{k=1, \dots, m} |x_i^{(k)} - x_j^{(k)}|$
- L_1 -метрика: $\rho(x_i, x_j) = \sum_{k=1}^m |x_i^{(k)} - x_j^{(k)}|$

$x_i = (x_i^{(1)}, \dots, x_i^{(m)})$ - вектор m признаков i -го объекта;
 $x_j = (x_j^{(1)}, \dots, x_j^{(m)})$ - вектор m признаков j -го объекта.

Что такое близкие объекты? Задана функция расстояния $\rho : X \times X \rightarrow [0, \infty)$.

Виды функций расстояния:

- Ланса-Уильямса: $\rho(x_i, x_j) = \frac{\sum_{k=1}^m |x_i^{(k)} - x_j^{(k)}|}{\sum_{k=1}^m (x_i^{(k)} + x_j^{(k)})}$
- косинусная мера: $\rho(x_i, x_j) = \frac{\sum_{k=1}^m x_i^{(k)} x_j^{(k)}}{\sqrt{\sum_{k=1}^m (x_i^{(k)})^2} \sqrt{\sum_{k=1}^m (x_j^{(k)})^2}}$

$x_i = (x_i^{(1)}, \dots, x_i^{(m)})$ - вектор m признаков i -го объекта;
 $x_j = (x_j^{(1)}, \dots, x_j^{(m)})$ - вектор m признаков j -го объекта.

Метод ближайших соседей

Для произвольного $x^* \in X$ отсортируем объекты $x_1, \dots, x_n$:

$$\rho(x^*, x_1) \leq \rho(x^*, x_2) \leq \dots \leq \rho(x^*, x_n)$$

x_i - i -ый сосед объекта x^* ; y_i - ответ на i -ом соседе объекта x^* .

Метрический алгоритм классификации:

$$a(x^*) = \arg \max_{y \in Y} \underbrace{\sum_{i=1}^n [y_i = y] \cdot w(i, x^*)}_{\Gamma_y(x^*)}$$

$w(i, x^*)$ - вес (степень важности) i -го соседа объекта x^* , неотрицателен, не возрастает по i .

$\Gamma_y(x^*)$ - оценка близости объекта x^* к классу y .

$$w(i, x^*) = [i \leq k] = \begin{cases} 1, & i \leq k, \\ 0, & i > k. \end{cases}$$

т.е. решение принимается только по k ближайшим соседям.

Преимущества:

- менее чувствителен к шуму;
- появился параметр k .

Взвешенный knn

$$a(u) = \arg \max_{y \in Y} \sum_{i=1}^k K \left(\frac{\rho(u, x_u^{(i)})}{h} \right) \mathbb{I}[y_u^{(i)} = y],$$

h - ширина окна

т.е. решение принимается только по k ближайшим

- $K(x) = \frac{1}{2} \mathbb{I}[|x| \leq 1]$ — прямоугольное ядро;
- $K(x) = (1 - |x|) \mathbb{I}[|x| \leq 1]$ — треугольное ядро (непрерывное);
- $K(x) = \frac{3}{4} (1 - x^2) \mathbb{I}[|x| \leq 1]$ — ядро Епанечникова (гладкое везде, кроме -1 и 1);
- $K(x) = \frac{15}{16} (1 - x^2)^2 \mathbb{I}[|x| \leq 1]$ — биквадратное ядро (гладкое везде);
- $K(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2}$ — гауссовское ядро (бесконечно гладкое везде).

- + простота реализации;
- + интерпретируемость решений;
- + вывод на основе прецедентов (case-based reasoning)
- неустойчивость к погрешностям (шуму, выбросам);
- отсутствие настраиваемых параметров;
- низкое качество классификации;
- приходится хранить всю выборку целиком.

Необходимо найти оптимальное значение k для различных задач



МЕТРИКИ КАЧЕСТВА ЗАДАЧА КЛАССИФИКАЦИИ

Ошибки первого и второго рода

- Ошибка первого рода (α -ошибка, ложноположительное заключение) — ситуация, когда отвергнута верная нулевая гипотеза (об отсутствии связи между явлениями или искомого эффекта).
- Ошибка второго рода (β -ошибка, ложноотрицательное заключение) — ситуация, когда принята неверная нулевая гипотеза.

Ошибка первого рода

- С учётом вышесказанного, ошибку первого рода часто называют ложной тревогой, ложным срабатыванием или ложноположительным срабатыванием. Если, например, анализ крови показал наличие заболевания, хотя на самом деле человек здоров, или металлодетектор выдал сигнал тревоги, сработав на металлическую пряжку ремня, то принятая гипотеза не верна, а следовательно совершена ошибка первого рода.

Ошибка второго рода

- Соответственно, ошибку второго рода иногда называют пропуском события или ложноотрицательным срабатыванием. Человек болен, но анализ крови этого не показал, или у пассажира имеется холодное оружие, но рамка металлодетектора его не обнаружила (например, из-за того, что чувствительность рамки отрегулирована на обнаружение только очень массивных металлических предметов).

Аккуратность, матрица ошибок

- Аккуратность

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- Матрица ошибок:
- $a(x)$ — это ответ алгоритма на объекте;
- y — истинная метка класса на этом объекте.

	$y = 1$	$y = 0$
$a(x) = 1$	Истинно-положительный (True Positive — TP)	Ложно-положительный (False Positive — FP)
$a(x) = 0$	Ложно-отрицательный (False Negative — FN)	Истинно-отрицательный (True Negative — TN)

Точность, полнота

- Точностью (precision) называется доля правильных ответов модели в пределах класса — это доля объектов действительно принадлежащих данному классу относительно всех объектов которые система отнесла к этому классу.

$$Precision = \frac{TP}{TP + FP}$$

- Полнота — это доля истинно положительных классификаций. Полнота показывает, какую долю объектов, реально относящихся к положительному классу, мы предсказали верно.

$$Recall = \frac{TP}{TP + FN}$$

Точность, полнота, многоклассовая классификация

- Имея матрицу ошибок, очень просто можно вычислить точность и полноту для каждого класса. Точность (precision) равняется отношению соответствующего диагонального элемента матрицы и суммы всей строки класса. Полнота (recall) — отношению диагонального элемента матрицы и суммы всего столбца класса.

$$Precision_c = \frac{A_{c,c}}{\sum_{i=1}^n A_{c,i}}$$

$$Recall_c = \frac{A_{c,c}}{\sum_{i=1}^n A_{i,c}}$$

Ф-мера

- Precision и recall не зависят, в отличие от accuracy, от соотношения классов и потому применимы в условиях несбалансированных выборок. Часто в реальной практике стоит задача найти оптимальный (для заказчика) баланс между этими двумя метриками. Понятно что чем выше точность и полнота, тем лучше. Но в реальной жизни максимальная точность и полнота не достижимы одновременно и приходится искать некий баланс. Именно такой метрикой является Ф-мера.
- Ф-мера представляет собой гармоническое среднее между точностью и полнотой

- Ф-мера достигает максимума при максимальной полноте и точности, и близка к нулю, если один из аргументов близок к нулю.


$$F = \frac{2 \times \textit{precision} \times \textit{recall}}{\textit{precision} + \textit{recall}}$$

- Взвешенная Ф-мера

$$F_{\beta} = \frac{(1 + \beta^2) \times \textit{precision} \times \textit{recall}}{(\beta^2 \times \textit{precision}) + \textit{recall}}$$

ROC-кривая

- Кривая рабочих характеристик (англ. Receiver Operating Characteristics curve). Используется для анализа поведения классификаторов при различных пороговых значениях. Позволяет рассмотреть все пороговые значения для данного классификатора. Показывает долю ложно положительных примеров (англ. false positive rate, FPR) в сравнении с долей истинно положительных примеров (англ. true positive rate, TPR).
- Один из способов сравнения классификаторов предусматривает измерение площади под кривой (англ. Area Under the Curve — AUC). Безупречный классификатор будет иметь площадь под ROC-кривой (ROC-AUC), равную 1, тогда как чисто случайный классификатор - площадь 0.5.



$$TPR = \frac{TP}{TP + FN} = Recall$$

$$FPR = \frac{FP}{FP + TN}$$

$$FPR = 1 - TNR,$$



МЕТРИКИ КАЧЕСТВА ЗАДАЧА РЕГРЕССИИ

- Средняя квадратичная ошибка (Mean Squared Error, MSE)
- MSE применяется в ситуациях, когда нам надо подчеркнуть большие ошибки и выбрать модель, которая дает меньше больших ошибок прогноза.

$$MSE = \frac{1}{n} \sum_{i=1}^n (a(x_i) - y_i)^2$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (a(x_i) - y_i)^2}$$

- Средняя абсолютная ошибка (Mean Absolute Error, MAE)

$$MAE = \frac{1}{n} \sum_{i=1}^n |a(x_i) - y_i|$$

- Коэффициент детерминации
- Коэффициент детерминации измеряет долю дисперсии, объясненную моделью, в общей дисперсии целевой переменной. Фактически, данная мера качества — это нормированная среднеквадратичная ошибка. Если она близка к единице, то модель хорошо объясняет данные, если же она близка к нулю, то прогнозы сопоставимы по качеству с константным предсказанием.

$$R^2 = 1 - \frac{\sum_{i=1}^n (a(x_i) - y_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- Это коэффициент, не имеющий размерности, с очень простой интерпретацией. MAPE=11.4% значит, что ошибка составила 11,4% от фактических значений. Основная проблема данной ошибки — нестабильность.

$$MAPE = 100\% \times \frac{1}{n} \sum_{i=1}^n \frac{|y_i - a(x_i)|}{|y_i|}$$

$$SMAPE = \frac{1}{n} \sum_{i=1}^n \frac{2 \times |y_i - a(x_i)|}{|y_i| + |a(x_i)|} \quad \text{symmetric MAPE}$$



МЕТРИКИ В ЗАДАЧАХ РАСПОЗНАВАНИЯ ИЗОБРАЖЕНИЙ

Классификация изображений

- Задача классификации изображений состоит в том чтобы
- каждому изображению поставить в соответствие класс,
- которому оно принадлежит

- Предположим, что N – количество категорий изображений
- Для каждого изображения $I_i, i = \overline{1, S}$ в выборке метод строит вектор достоверностей $p^i = (p_1^i, p_2^i, \dots, p_N^i)$, где p_i^j – достоверность того, что изображение I_j принадлежит классу i
- **Точность top-K** (top-K accuracy) определяется следующим образом:

где

$$topK = \frac{\sum_{j=1}^S 1_{\{i_1^j, i_2^j, \dots, i_K^j\}}(l_j)}{S}$$

достоверностей, l_j – класс, которому принадлежит изображение I_j согласно разметке, $1_{\{i_1^j, i_2^j, \dots, i_K^j\}}(l_j)$ –


индикаторная функция

Детектирование объектов

- Задача детектирования состоит в том, чтобы каждому изображению I поставить в соответствие множество положений объектов B интересующих классов:

$$\varphi: I \rightarrow B, \quad B = \{b_k, k = \overline{0, |B| - 1}\},$$

где $b_k = ((x_1^k, y_1^k), (x_2^k, y_2^k), [s^k, c^k])$, $s^k \in \mathbb{R}$ – достоверность, c^k – класс объектов («СТОЛ», «ПЕШЕХОД», «АВТОМОБИЛЬ», «АВТОБУС» и т.п.)



- Показатель числа истинных срабатываний** (true positive rate) – отношение количества правильно обнаруженных объектов TP к общему числу размеченных объектов $TP + FN$

$$TPR = \frac{TP}{TP + FN}$$

- Считается, что объект обнаружен правильно, если доля перекрытия обнаруженного (detection, d) и размеченного (groundtruth, g) окаймляющих прямоугольников $IoU = \frac{S_{d \cap g}}{S_{d \cup g}}$ превышает некоторое пороговое значение τ
- Порог τ выбирается в промежутке от 0.5 до 0.7

Разметка

Предсказание

	True	False
True	TP	FN
False	FP	TN

- ❑ **Показатель числа ложных срабатываний** (false detection rate) – отношение количества ложных срабатываний к общему числу срабатываний детектора

$$FDR = \frac{FP}{TP + FP}$$

- ❑ Объект считается обнаруженным правильно при выполнении тех же условий, что и для предыдущего показателя
- ❑ Обнаруженный прямоугольник принимается за ложное срабатывание, если ему не нашлась пара из разметки

		Предсказание	
		True	False
Разметка	True	TP	FN
	False	FP	TN


- ❑ **Количество ложных срабатываний, в среднем приходящихся на изображение** (average false positives per frame) – отношение количества ложных срабатываний FP к общему числу обработанных изображений N

$$FPperFrame = \frac{FP}{N}$$

- ❑ Объект считается обнаруженным правильно при выполнении тех же условий, что и для предыдущих показателей

Точность

- $IoU = \frac{S_{d \cap g}}{S_{d \cup g}}$ – доля перекрытия обнаруженного (detection) и размеченного (groundtruth) окаймляющих прямоугольников (Intersection over Union), $IoU \in [0; 1]$
- TP – количество объектов, для которых доля перекрытия не меньше некоторого порога τ (т.е. считается, что объект обнаружен правильно – true positive)
- FP – количество обнаруженных объектов с долей перекрытия, меньшей τ (объект найден ошибочно), или объект обнаружен более одного раза (false positives)
- FN – количество необнаруженных объектов (false negatives)



Средняя точность предсказания

- **Средняя точность предсказания** (average precision) – математическое ожидание точностей

$$AP = \int_0^1 p(r)dr$$

- Схема вычисления:

- Обнаруженные окаймляющие прямоугольники сортируются в порядке убывания достоверности наличия в них объектов
- Для каждого обнаруженного прямоугольника выполняется поиск соответствия из разметки согласно условию $IoU \geq \tau$
- Выполняется вычисление точности и отклика
- Строится зависимость точности от отклика
- Вычисляется площадь под графиком построенной зависимости





МЕТРИКИ КАЧЕСТВА В ЗАДАЧАХ РАСПОЗНАВАНИЯ ТЕКСТА

- Word Recognition Rate (WRR) — точность распознавания, которая определяется как процент правильно распознанных слов, и родственная ей, Word Error Rate (WER) — процент неправильно распознанных слов.

Чем метрика WER ближе к нулю, тем выше точность распознавания.

где S — количество операций замены слов,
I — количество операций вставки слов,
D — количество операций удаления слов,
T — количество слов в эталонной фразе,
H — количество верно распознанных слов.

WER

- Метрика WER представляет собой «стоимость» для преобразования одной строки (эталонной) во вторую (гипотеза, результат транскрибации) с наименьшим числом операций замены (S), удаления (D) и вставки (I) слов

Метрика Character Error Rate (CER) вычисляется так же как WER, но не для слов, а для отдельных символов.

$$WER = \frac{S + D + I}{T} = \frac{S + D + I}{S + D + H}$$

Применяется также: ошибка распознавания соответствий – Math Error Rate (MER) и показатель потери информации Word Information Lost (WIL).

$$MER = \frac{S + D + I}{H + S + D + I}$$

$$WIL = 1 - \frac{H^2}{T \cdot T_0}$$

Для оценки скорости распознавания может быть использована метрика Real Time Factor (Коэффициент реального времени) – показатель отношения времени распознавания к длительности распознаваемого сигнала, также известного как Speed Factor (SF).

$$SF = \frac{T_{\text{расп}}}{T}$$

где $T_{\text{расп}}$ – время распознавания сигнала, T – его длительность. Коэффициент измеряется в долях от реального времени.



КРОСС ВАЛИДАЦИЯ

КРОСС ВАЛИДАЦИЯ

- Метод скользящего контроля или перекрестной проверки.
- В этом случае фиксируется некоторое множество разбиений исходной выборки на две подвыборки: обучающую и контрольную. Для каждого разбиения выполняется настройка алгоритма по обучающей подвыборке, затем оценивается его средняя ошибка на объектах контрольной подвыборки. Оценкой скользящего контроля называется средняя по всем разбиениям величина ошибки на контрольных подвыборках.



СОРЕВНОВАНИЯ

СОРЕВНОВАНИЕ

- В таблицах результатов соревнований часто используется ранжирование, учитывающее качество работы модели, время загрузки решения, время выполнения решения на устройстве (или серии устройств).